

UNIT 35-01. 회귀 모형의 해석

단순 회귀 모형의 예

```
2 set.seed(2)
3 x = runif(50, 0, 5)
4 y = 5 + 2 * x + rnorm(50, 0, 0.5)
5 df <- data.frame(x, y)
6 fit <- lm(y~x, data=df)
7 fit
```

Call:

```
lm(formula = y ~ x, data = dfrm)
```

Coefficients:

(Intercept)

4.748

절편

2.072


기울기 회귀계수

회귀계수(regression coefficient)

- 독립변수가 종속변수에 미치는 영향을 수치로 나타내는 값으로, 기울기 회귀계수(slope)와 절편(intercept)이 있음
- 회귀모형을 통해 추정되는 모수(parameter)임
- 기울기 회귀계수는 독립변수 1개당 1개씩 존재하며, 절편은 모형 전체에 1개만 존재함
- 절편 : 독립변수가 모두 0의 값을 가질 때, 종속변수의 예상값

회귀 방정식

$$y = 2.072 * x + 4.748$$



- `fit <- lm(y~x, data=df)`: df라는 이름의 데이터셋에서 y를 종속변수, x를 독립변수로 하는 선형 모델(Linear Model)을 생성해 fit이라는 이름을 지정함
- `set.seed(정수)`: 난수를 발생할 때 특정 규칙을 따르도록 지정하는 것으로, 여러 번 반복 수행해도 동일한 난수가 발생되므로 동일한 결과를 갖는 데이터를 생성할 수 있게 됨 (정수는 어떤 것을 사용해도 된다.)
- `y=5+2*x+rnorm(50, 0, 0.5)`: 'y=5+2x+오차'인 모형



다중 회귀 모형의 예

```
set.seed(10)
u <- runif(50, 0, 6)
v <- runif(50, 6, 12)
w <- runif(50, 3, 25)
y = 3 + 0.5 * u + 1 * v - 2*w + rnorm(50, 0, 0.5)
df <- data.frame(y, u, v, w)
```

데이터셋 생성

절편이 3이고, u, v, w의 기울기 회귀계수가 각각 0.5, 1, -2인 3개의 독립변수를 갖고, 정규분포의 오차를 갖는 데이터를 생성한다.

다중회귀 모형 생성

```
> a <- lm(y~u+v+w, df)
> a
```

df라는 이름의 데이터셋에서 y를 종속변수, u, v, w를 독립변수로 하는 선형 모델을 생성하고, 그 결과를 a라는 이름으로 지정하는 것

Call:
lm(formula = y ~ u + v + w, data = df)

Coefficients:
(Intercept)

3.4374

절편

종속변수

독립변수

u	v	w
0.4676	0.9556	-1.9923

기울기 회귀계수

회귀 방정식

$$y = 3.4374 + 0.4676*u + 0.9556*v - 1.9923*w$$



표본 회귀선의 유의성 검정

- 두 변수 사이에 선형관계가 성립하는지 검정하는 것
- 귀무가설: 회귀식의 기울기 계수 β_1 은 0과 같다. 대립가설: 회귀식의 기울기 계수 β_1 은 0과 같지 않다.

회귀모형의 해석

모형이 통계적으로 유의미한가?

F 통계량의 유의확률(p-value)로 확인

회귀계수들이 유의미한가?

회귀계수의 t값에 대한 유의확률(p-value)로 확인

모형이 얼마나 설명력을 갖는가?

결정계수(R^2) 확인

모형이 데이터를 잘 적합하고 있는가?

잔차를 그래프로 그려 회귀 진단 수행

데이터가 모형 가정을 만족시키는지 확인함

모형 가정: 선형성, 독립성, 등분산성, 비상관성, 정상성

F 통계량, p-value

F 통계량 = 회귀제곱평균(MSR) / 잔차제곱평균(MSE)

- 모델의 통계적 유의성을 검정하기 위한 검정통계량
- F 통계량이 클수록 회귀 모형은 통계적으로 유의함
- F 통계량에 대한 p-value ≤ 0.05 일 때 통계적으로 유의함

t 값, p-value


t 값 = Estimate(회귀계수) / Std.Error(표준오차)

- t 통계량이 크다는 것은 표준오차가 작다는 의미
- t 통계량이 클수록 회귀계수가 유의함
- t 값에 대한 p-value ≤ 0.05 일 때 통계적으로 유의함



결정계수
 $R^2 = SSR/SST$

- 결정계수(R^2) = $\frac{SSR(\text{회귀제곱합})}{SST(\text{총제곱합})}$, $1 - \frac{SSE(\text{잔차제곱합})}{SST(\text{총제곱합})}$
- 회귀식의 적합도(설명력)를 측정하는 척도로, 0~1 사이의 범위를 가짐
- 결정계수가 1에 가까울수록 회귀방정식의 설명력이 높아짐
- 전체 분산 중 모델에 의해 설명되는 분산의 양



$$\sum_{i=1}^n \overset{SST}{(y_i - \bar{y})^2} = \sum_{i=1}^n \overset{SSE}{(y_i - \hat{y}_i)^2} + \sum_{i=1}^n \overset{SSR}{(\hat{y}_i - \bar{y})^2}$$

- SST(Total Sum of Squares) : Y의 전체 변동성
- SSE(Error Sum of Squares) : X를 통해 설명하지 않는 Y의 변동성
- SSR(Regression Sum of Squares) : X로 설명 가능한 Y의 변동성

UNIT 35-05. 회귀 모형의 해석

```
> a <- lm(y~u+v+w, df)
> summary(a)
```

Call:
lm(formula = y ~ u + v + w, data = df)

Residuals: 회귀계수 표준오차
Min 1Q Median 3Q Max
-1.06096 -0.31857 0.06092 0.32280 1.03220

Coefficients: t 값=Estimate/Std.Error

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.43742	0.46949	7.322	3.01e-09 ***
u	0.46762	0.04419	10.581	6.55e-14 ***
v	0.95558	0.04546	21.019	< 2e-16 ***
w	-1.99230	0.01052	-189.459	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4695 on 46 degrees of freedom

Multiple R-squared: 0.9988, Adjusted R-squared: 0.9987

F-statistic: 1.254e+04 on 3 and 46 DF, p-value: < 2.2e-16

- Signif. codes: 회귀계수(Estimate)나 절편(Intercept)이 유의한지를 *, . 등의 표기로 빠르게 인지할 수 있도록 돕는 도구
- '***', '**', '*': '***': 0에서 0.001 사이의 값, '**': 0.001에서 0.01 사이의 값, '*': 0.01 ~ 0.05 사이의 값을 나타냄
- 5% 유의수준 하에서 Signif. codes에 * 이 없는 경우는 통계적인 유의미가 없다고 판단할 수 있음

t 값에 대한 p-value: 회귀계수들이 유의미한가?
u, v, w 모두 통계적으로 유의미함

R²: 모형이 얼마나 설명력을 갖는가?

Multiple R-squared: 0.9988

Adjusted R-squared: 수정된 결정계수, 0.9987, 단순히 변수의 수가 많아지는 것에 따라 높은 점수가 될 수 있는 것에 대해 보정한 값

F 통계량: 모형이 통계적으로 유의미한가?

p-value(2.2e-16) < 0.05 이므로 통계적으로 유의미함

- 다중회귀모형의 자유도 df = n - k - 1 # n은 sample 수, k는 독립변수의 수, 즉 n=46 + 3 + 1 = 50



앞장에 이어서 설명

Call:
lm(formula = y ~ u + v + w, data = df)

Residuals:

회귀계수

Min	1Q	Median	3Q	Max
-1.06096	-0.31857	0.06092	0.32280	1.03220

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3.43742	0.46949	7.322	3.01e-09	***
u	0.46762	0.04419	10.581	6.55e-14	***
v	0.95558	0.04546	21.019	< 2e-16	***
w	-1.99230	0.01052	-189.459	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4695 on 46 degrees of freedom
Multiple R-squared: 0.9988, Adjusted R-squared: 0.9987
F-statistic: 1.254e+04 on 3 and 46 DF, p-value: < 2.2e-16

회귀계수 해석

- 회귀 모형의 결과로 찾아진 회귀계수는 파라미터(parameter)라고 한다.
- (Intercept) : 모든 독립변수(u, v, w)가 0일 때, y의 예측값(절편)
- u가 1 단위 증가하면, 다른 변수(v, w)가 일정할 때 y는 평균적으로 0.46762 증가
- v가 1 단위 증가하면, 다른 변수들이 일정할 때 y는 평균적으로 0.95558 증가
- w가 1 단위 증가하면, 다른 변수들이 일정할 때 y는 평균적으로 1.99230 감소

- 더미변수가 독립변수로 사용된 경우 절편이 범주별로 다름
- 예) gender 변수가 있고 남자(male)=0, 여자(female)=1 인 경우
- 회귀식 : $y = \beta_0 + \beta_1 \cdot \text{gender}$
- gender가 0인 경우 : $y = \beta_0$
- gender가 1인 경우 : $y = \beta_0 + \beta_1$

[SIDE] 더미변수(dummy variable): 범주형 변수(categorical variable)를 0과 1의 숫자로 변환해 표현한 변수



교호작용항 해석

- 교호작용은 **한 변수의 효과가 다른 변수의 수준에 따라 달라지는 관계를 말함**
- 교호작용항이 유의하다는 것은 두 변수의 효과가 **독립적이지 않다**는 의미로, 한 변수가 종속변수에 미치는 영향이 다른 변수의 수준에 따라 달라짐
- 교호작용항 A:B의 해석은 A와 B가 어떤 변수 형태(연속형/범주형)인지에 따라 달라짐

A,B 모두
연속형 변수

$$sales = \beta_0 + \beta_1 TV + \beta_2 radio + \beta_3 (TV \times radio)$$

- TV와 radio 광고비가 동시에 증가할 때, 판매량 변화가 단순합보다 더 크거나 작을 수 있음을 의미
- TV의 효과(기울기)는 radio의 수준에 따라 달라짐. 즉, radio가 높을수록 TV 광고의 효과가 커지거나 작아짐
- β_3 는 TV와 radio가 1단위씩 동시에 증가할 때 추가적인 변화량을 나타내며, **부호가 양수이면 시너지 효과(Synergy Effect) 존재, 음수이면 상쇄 효과(Counter Effect) 존재, 0이면 독립 관계를 의미함**

A 연속형,
B 범주형 변수

$$sales = \beta_0 + \beta_1 TV + \beta_2 promotion + \beta_3 (TV \times promotion)$$

- promotion No(0) 일 때 $sales = \beta_0 + \beta_1 TV$: 판촉이 없을 때 TV 광고의 효과는 β_1 이다.
- promotion Yes(1) 일 때 $sales = \beta_0 + \beta_2 + (\beta_1 + \beta_3)TV$: 판촉이 있을 때 TV 광고의 효과는 $\beta_1 + \beta_3$ 이다.
- 즉, β_3 은 판촉(promotion) 여부에 따라 TV 광고 효과(기울기)가 얼마나 달라지는지를 나타냄
- $\beta_3 > 0$, 유의함($p \leq 0.05$) : 판촉을 할 경우 TV 광고의 효과가 더 커진다 → 시너지 효과 존재
- $\beta_3 < 0$, 유의함($p \leq 0.05$) : 판촉을 할 경우 TV 광고의 효과가 감소한다 → 상쇄 효과 존재
- β_3 , 유의하지 않음($p > 0.05$) : 판촉 여부에 따라 TV 광고의 효과가 유의하게 달라지지 않음



swiss 데이터셋

스위스의 47개 프랑스어 사용지역의 출산율(Fertility)과 관련된 변수들을 사용하여 얻은 다중선형회귀 분석의 결과

```
> summary(lm(Fertility~., data=swiss))
```

Call:

```
lm(formula = Fertility ~ ., data = swiss)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.2743	-5.2617	0.5032	4.1198	15.3213

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	66.91518	10.70604	6.250	1.91e-07	***
Agriculture	-0.17211	0.07030	-2.448	0.01873	*
Examination	-0.25801	0.25388	-1.016	0.31546	
Education	-0.87094	0.18303	-4.758	2.43e-05	***
Catholic	0.10412	0.03526	2.953	0.00519	**
Infant.Mortality	1.07705	0.38172	2.822	0.00734	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom

Multiple R-squared: 0.7067, Adjusted R-squared: 0.671

F-statistic: 19.76 on 5 and 41 DF, p-value: 5.594e-10

- lm(Fertility~., data=swiss) : swiss 데이터셋에서 Fertility를 종속변수로 사용하고, 나머지 모든 변수를 독립변수로 사용함
- 독립변수 5개: Agriculture, Examination, Education, Catholic, Infant.Mortality
- 위의 회귀모형은 출산율 변동의 70.67%를 설명함 (Multiple R-squared: 0.7067이기 때문)
- 수정결정계수는 0.671이다. (Adjusted R-squared: 0.671이기 때문)
- 유의수준 0.05 하에서 위의 회귀모형은 유의적으로 출산율(Fertility)을 설명하고 있다.F-statistic에 대한 p-value가 5.594e-10 으로 0.05보다 작은 값이기 때문
- Examination 변수는 p-value가 0.31546으로 통계적 유의미를 갖지 않음
- 만일, 모든 또는 특정 설명변수가 출산율 변동의 **원인임을 보여준다고 하면 틀린 지문이 됨 (원인 = 인과관계)**



Orange 데이터셋

나무 종류(Tree)와 나무의 둘레(circumference), 연령(age)을 가지고 있으며, 나무 종류(Tree)는 5가지 범주를 가짐

```
> model <- lm(circumference ~ age + Tree, data = Orange)
> summary(model)
```

```
Call:
lm(formula = circumference ~ age + Tree, data = Orange)
```

Residuals:

Min	1Q	Median	3Q	Max
-30.505	-8.790	3.737	7.650	21.859

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.457493	7.572732	-0.589	0.5607
age	0.106770	0.005321	20.066	< 2e-16 ***
Tree1	5.571429	8.157252	0.683	0.5000
Tree5	17.142857	8.157252	2.102	0.0444 *
Tree2	41.285714	8.157252	5.061	2.14e-05 ***
Tree4	45.285714	8.157252	5.552	5.48e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.26 on 29 degrees of freedom
Multiple R-squared: 0.9399, Adjusted R-squared: 0.9295
F-statistic: 90.7 on 5 and 29 DF, p-value: < 2.2e-16

- `lm(circumference~age + Tree, data=Orange)` : Orange 데이터셋에서 circumference를 종속변수로 사용하고, age와 Tree를 독립변수로 사용함
- Age는 연속형 변수, Tree는 범주형 변수 (Tree.2, Tree.3, Tree.3, Tree.5 와 같이 Tree 뒤에 범주가 표기되어 있음)
- dummy 변수가 4개이기 때문에 Tree의 범주는 5개라는 것을 알 수 있음
- age가 증가할수록 circumference가 증가함(Estimate가 양수이기 때문)
- 위의 모형은 F-statistic의 p-value가 < 2.2e-16으로 0.05보다 작으므로 유의수준 0.05하에서 통계적으로 유의미함
- 독립변수(=설명변수) 중에서 age와 Tree.2, Tree.4 만 유의미하고, Tree.3, Tree.5는 유의하지 않음
- 결정계수는 0.9399로 매우 높음



College 데이터셋

졸업률(Grad.Rate)와 Private, Top10perc, Outstate, Expend 변수를 가지고 있음

```
> summary(College)
```

Private	Top10perc	Outstate	Expend	Grad.Rate
No :212	Min. : 1.00	Min. : 2340	Min. : 3186	Min. : 10.00
Yes:565	1st Qu.:15.00	1st Qu.: 7320	1st Qu.: 6751	1st Qu.: 53.00
	Median :23.00	Median : 9990	Median : 8377	Median : 65.00
	Mean :27.56	Mean :10441	Mean : 9660	Mean : 65.46
	3rd Qu.:35.00	3rd Qu.:12925	3rd Qu.:10830	3rd Qu.: 78.00
	Max. :96.00	Max. :21700	Max. :56233	Max. :118.00

```
> summary(lm(Grad.Rate ~., data=College))
```

Call:

```
lm(formula = Grad.Rate ~ ., data = College)
```

Residuals:

Min	1Q	Median	3Q	Max
-47.317	-8.503	-0.245	7.741	58.760

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	39.4130270	1.3579828	29.023	< 2e-16 ***
PrivateYes	2.9131163	1.3431005	2.169	0.030391 *
Top10perc	0.3209807	0.0379053	8.468	< 2e-16 ***
Outstate	0.0018820	0.0001988	9.467	< 2e-16 ***
Expend	-0.0004723	0.0001423	-3.320	0.000943 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.51 on 772 degrees of freedom
Multiple R-squared: 0.3843, Adjusted R-squared: 0.3811
F-statistic: 120.5 on 4 and 772 DF, p-value: < 2.2e-16

- lm(Grad.Rate ~. data=College) College 데이터셋에서 Grad.Rate를 종속변수로 사용하고, 다른 모든 변수를 독립변수로 사용함
- Top10perc, Outstate, Expend는 연속형 변수, Private는 범주형 변수임 (PrivateYes 와 같이 Private 뒤에 범주가 표기되어 있음)

- 회귀식: $\text{Grad.Rate} = 2.9131163 \times \text{PrivateYes} + 0.3209807 \times \text{Top10perc} + 0.0018820 \times \text{Outstate} - 0.0004723 \times \text{Expend} + 39.4130270$
- dummy 변수가 1개이기 때문에 Private의 범주는 2개라는 것을 알 수 있음 (PrivateYes → dummy변수)
- Top10perc의 Estimate가 양수이므로 Top10perc(고교성적 상위 10%학생의 비율)이 높을수록 졸업률이 높아진다(Estimate가 음수라면 졸업률이 낮아짐).
- PrivateYes의 Estimate가 양수이므로, 다른 설명변수의 조건이 동일할 때 사립학교(PprivateYes)의 졸업률이 공립학교(PprivateNo)에 비해 더 높다.
- F-statistic의 p-value가 < 2.2e-16으로 0.05보다 작으므로 유의수준 5%에서 모형은 통계적으로 유의미함
- 모든 독립변수가 유의미함(즉, 모든 변수는 졸업률에 유의한 영향을 미치는 변수)
- 결정계수는 0.3843으로 매우 낮음



Wage 데이터셋

- 근로자의 임금 관련 데이터이다. 임금(wage)을 예측하기 위해 나이(age)와 직군(jobclass) 변수를 함께 사용한다.

```
> Wage = read.csv('data/Wage_dataset.csv', stringsAsFactors=TRUE)
> summary(Wage[, c('wage', 'age', 'jobclass')])
```

wage	age	jobclass
Min. : 20.09	Min. :18.00	1. Industrial :1544
1st Qu.: 85.38	1st Qu.:33.75	2. Information:1456
Median :104.92	Median :42.00	
Mean :111.70	Mean :42.41	
3rd Qu.:128.68	3rd Qu.:51.00	
Max. :318.34	Max. :80.00	

Wage 데이터셋에서 'wage', 'age', 'jobclass' 라는 3개의 변수를 가져와 summary를 출력함

- wage, age 두 개의 변수는 연속형 변수이며, jobclass는 범주형 변수인 것을 알 수 있음
- wage, age는 Min, 1st Qu, Median, Mean, 3rd Qu, Max.을 알 수 있는데 이것은 각각 최소값, 제1사분위수(=25% 위치값), 중위수(=50% 위치값, 중앙값), 평균, 제3사분위수(=75% 위치값), 최대값임
- jobclass는 '1. Industrial', '2. Information'이라는 두 개의 범주로 구성되어 있으며, 총 데이터 수는 3000개임



Wage 데이터셋

wage를 종속변수로, age와 jobclass를 독립변수로 사용하며, age와 jobclass의 교호작용을 포함하여 선형회귀 분석을 실행한다.

```
> model <- lm(wage ~ age + jobclass + age*jobclass, data=Wage)
> summary(model)
```

```
Call:
lm(formula = wage ~ age + jobclass + age * jobclass, data = Wage)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-105.656  -24.568   -6.104   16.433   196.810
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    73.52831     3.76133   19.548 < 2e-16 ***
age             0.71966     0.08744    8.230 2.75e-16 ***
jobclass2. Information 22.73086     5.63141    4.036 5.56e-05 ***
age:jobclass2. Information -0.16017     0.12785   -1.253 0.21
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 40.16 on 2996 degrees of freedom
Multiple R-squared:  0.07483,    Adjusted R-squared:  0.07391
F-statistic: 80.78 on 3 and 2996 DF,  p-value: < 2.2e-16
```

1) 분석결과 wage에 대한 회귀식은 $wage = 0.72*age + 22.73*jobclass2. Information - 0.16*age:jobclass2. Information + 73.52$ 인 것을 알 수 있다.

2) age는 연속형 변수, jobclass2. Information은 더미 변수(dummy variable)이다.

- 위의 summary의 결과를 보았을 때 jobclass는 범주형 변수이고, lm함수를 통한 분석을 하면서 자동으로 더미 변수화 된다.
- 범주형 변수가 더미 변수가 될 때는 범주의 수 - 1 만큼의 더미 변수가 생성되며, '변수명+범주명'의 형태로 더미 변수의 이름이 정해진다.
- jobclass는 '1. Industrial' 과 '2. Information'이라는 두 개의 범주가 있는데 기준 범주(baseline)인 '1. Industrial'이 제외되고 '2. Information'만 더미 변수로 생성된다.

기준 범주(Baseline Category) 범주형 변수(factor)를 회귀모형에 사용할 때, 여러 범주 중 하나를 기준(reference)으로 삼고 나머지와의 비교를 수행하는 기준 역할을 하는 범주를 말한다. 기준 범주는 더미 변수 생성에서 제외되며, 결과 해석 시에는 '더미 변수의 계수는 기준 범주에 비해 어떤 영향을 미치는지'를 해석하게 된다.



Wage 데이터셋

4) 직업군(jobclass)이 동일 할 때 나이가 많을수록 임금이 증가하는 경향이 있다.

age에 대한 Estimate가 양수(0.71966)이므로 나이가 많을수록 임금이 증가한다는 것을 알 수 있다. (만일 음수였다면 임금이 감소함)

5) 나이가 동일할 때, Information 직군이 Industrial 직군에 비해 평균적으로 임금이 높다.

- wage 회귀식을 보았을 때 Information 직군에 대한 더미 변수만 존재하고 Information 직군의 Estimate가 양수(22.73086)이기 때문에 Information 직군의 임금이 Industrial 직군에 비해 높다고 할 수 있다.
- Industrial 직군은 회귀식에 포함되어 있지 않기 때문에 wage에 영향을 주지 않는다. (만일 Information 직군에 대한 Estimate가 음수였다면, Information 직군의 임금이 Industrial 직군에 비해 낮다고 할 수 있다.)

6) 나이에 따라 두 직군 간의 임금의 평균 차이가 유의하게 변하지 않는다.

- 나이(age)에 따른 직군(jobclass)간의 임금의 평균 차이에 대한 유의미 여부는 교호작용이라고 하며, 'age:jobclass2. Information'의 p-value를 확인하여 알 수 있다.
- p-value가 0.21이므로 유의수준 0.05 보다 크기 때문에 나이에 따라 두 직군간의 임금의 평균 차이가 유의하다고 할 수 없다.

7) 회귀식은 유의수준 0.05에서 임금의 변동성을 설명하는데 유의하다.

- 회귀식에 대한 유의성은 F-statistic의 p-value를 보고 확인할 수 있다. 위의 결과에서 살펴보면 p-value: $< 2.2e-16$ 이고, p-value $< 2.2 * 10^{-16}$ 이므로 유의하다고 할 수 있다.

8) age, jobclass2. Information 두 개의 변수는 모두 통계적으로 유의하다.

- 변수에 대한 유의성은 각 변수의 p-value를 보고 확인할 수 있다.
- p-value $<$ 유의수준(0.05) 이므로 두 변수는 모두 통계적으로 유의하다고 할 수 있다.



Wage 데이터셋

9) **age:jobclass2. Information** 은 **교호작용항**이다.

- 나이(age)에 따른 임금 변화율(기울기)이 직업유형(jobclass)에 따라 달라지는가를 나타내는 항이다.
- age는 연속형 변수, jobclass2.Information은 범주형 이진 변수(0/1)이므로, age와 jobclass2. Information의 교호작용 효과는 jobclass2. Information일 때 age의 효과가 estimate 만큼 더 커지거나 작아짐을 나타낸다.
- jobclass가 1.Industrial(0) 인 경우: $wage = 73.52 + 0.72 \times age$
- jobclass가 2.Information(1) 인 경우: $wage = 73.52 + 22.73 + (0.72 - 0.16) \times age$
- estimate가 -0.16017이므로 Information 직군에서는 연령 증가에 따른 임금 증가폭이 Industrial보다 약 0.16 더 작다.
- p-value 값이 0.21이므로 유의수준 5%에서 두 직군 간 나이에 따른 임금 상승률의 차이가 통계적으로 유의미하다고 보기 어렵다.
- "통계적으로 유의하지 않다"는 것은 교호작용 효과가 완전히 없다는 뜻이 아니라, 표본 내에서 유의하게 검증되지 않았음을 의미한다.
- 즉, Information 직군의 나이에 따른 임금 변화율이 Industrial보다 다소 완만하지만 그 차이가 통계적으로 크지 않다.

10) wage에 대해 서로 다른 job인 경우 y절편은 변한다.

- 절편(intercept)은 age = 0일 때 예상되는 wage를 의미한다.
- jobclass가 1.Industrial(0) 인 경우: $wage = 73.52$
- jobclass가 2.Information(1) 인 경우: $wage = 73.52 + 22.73 = 96.26$



로지스틱회귀 모형의 이해

- 종속변수가 범주형인 경우 적용되는 회귀분석 모형
- 종속변수와 독립변수 간의 관계식을 이용하여 종속변수가 성공/실패, 사망/생존과 같이 두 개의 집단을 갖는 이항 분류 및 그 이상의 집단을 갖는 다항 분류에 사용되는 분류 기법
- 일반 선형회귀(General Linear Regression)는 X 값의 변화에 따른 Y 값의 변화를 설명하며, X가 1 증가할 때 Y는 회귀계수만큼 증가한다고 해석하며, 로지스틱 회귀는 Y가 성공일 확률에 대한 것을 선형 모델로 알아내는 것

	일반 선형회귀	로지스틱 회귀
분석 종류	지도학습 - 회귀(Regression)	지도학습 - 분류(Classification)
종속변수	연속형 변수, 정규분포	이산형(범주형) 변수, 이항분포
가정	선형성 및 오차항에 대한 가정 있음	없음
수식	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$	$P(Y = 1 X) = \frac{1}{1 + e^{-z}}, (z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)$
모형 탐색 방법	최소제곱법(OLS)	최대우도법(MLE), 가중최소자승법(WLS) (WLS는 일부 근사 계산 시 사용)
모형 검정	F-test, T-test	χ^2 test
출력 범위	$-\infty \sim \infty$	0 ~ 1

UNIT 41-03. 분류 분석 : 로지스틱 회귀 모형



로지스틱 회귀 모형은 Y가 성공일 확률을 선형모델로 알아내는 것으로, 로그 오즈(log odds)를 예측해 확률로 변환하는 과정을 거침

1. 선형결합을 통해 $P(Y=1)$ 의 log odds(=logit)를 예측한다.

$$\text{logit}(P(Y = 1)) = \log \left(\underbrace{\frac{P(Y = 1)}{1 - P(Y = 1)}}_{\text{승산(odds)}} \right) = \underbrace{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n}_{\text{선형예측자(Linear predictor, z)}}$$

2. log odds(=logit) 값을 sigmoid 함수에 적용해 $P(Y=1)$ 의 확률로 변환한다.

$$P(Y = 1) = \underbrace{\frac{1}{1 + e^{-z}}}_{\text{sigmoid 함수}}, \text{ where } z = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n$$

sigmoid 함수 적용 시, 선형회귀는 z를 그대로 예측 값으로 사용하지만, 로지스틱 회귀는 z를 log odds로 보고 sigmoid 함수를 적용하여 이를 확률로 해석함

승산(odds)	$odds = \frac{P(Y = 1)}{P(Y = 0)}$, 사건이 일어날 확률을 일어나지 않을 확률로 나눈 값. 즉, 성공 대비 실패의 비율로 $0 < odds < \infty$ 값을 가짐
로그 오즈(log odds) = logit = 선형예측자	로그 오즈는 odds에 log 함수를 적용한 것으로 log(odds), logit, 선형예측자로 표기하며 $-\infty < \text{logit} < \infty$ 값을 가짐 $\text{log(odds)} = \log \left(\frac{P(Y = 1)}{1 - P(Y = 1)} \right) = \log \left(\frac{P(Y = 1)}{P(Y = 0)} \right) = z = \beta_0 + \beta_1 \cdot x_1$
시그모이드(sigmoid)	$P(Y = 1) = \frac{1}{1 + e^{-z}}$, $z = \text{선형예측자} = \text{log(odds)}$, 즉, 시그모이드는 선형예측자 z를 0~1 범위의 확률로 변환하는 함수




```
prob <- 0.8
odds <- prob / (1-prob)
log_odds <- log(odds)
r <- 1 / (1 + exp(-log_odds))
```

Values	
log_odds	1.38629436111989
odds	4
prob	0.8
r	0.8

→ 성공이 일어날 가능성이 실패보다 4배

- **승산(odds) = 성공률 / 실패율, $P_i / (1-P_i)$ 단, P_i = 성공률**
 - 성공이 일어날 가능성이 크면 1.0 보다 큰 값, 실패가 발생할 가능성이 크면 1.0 보다 작은 값
 - 확률을 $0 < odds < \infty$ 범위로 변환한 값
- **로그 오즈(log odds) = logit = log(odds)**
 - 로그 오즈(log odds)는 odds값에 log를 취해 선형화(linearization)한 값으로, $\log(odds(p)) = ax + b$ 형태처럼 선형 분석이 가능하며, 값의 범위는 $-\infty < \log odds < \infty$ 을 가짐
 - 로지스틱 회귀 모형의 **회귀계수(β)** 는 독립변수(X)가 1 단위 증가할 때 **로그 오즈(log odds)**가 선형적으로 얼마나 변하는지를 나타냄
- **시그모이드(sigmoid) 함수**
 - 로지스틱(logistic) 함수라 불리기도 하며, log odds 값을 **연속형 0~1** 사이의 확률로 바꾸는 함수
 - 비선형 값을 얻기 위해 사용

$$y^{sigmoid} = \frac{1}{1 + e^{-x}}$$



UNIT 41-05. 분류 분석 : 로지스틱 회귀 모형



```
prob_a <- 0.5
prob_b <- 0.2
odds_a <- prob_a / (1-prob_a)
odds_b <- prob_b / (1-prob_b)
odds_ratio <- odds_a / odds_b
```

Values	
odds_a	1
odds_b	0.25
odds_ratio	4

- 승산비(odds ratio): 다른 변수가 일정하고 예측변수 x_1 이 한 단위 증가할 때, 성공($Y=1$)의 오즈(odds)가 몇 배 증가 또는 감소하는지 나타내는 지표
- $odds\ ratio = odds_a / odds_b = \exp(coef) = \exp(5.140336) = 170.7731385$
 - 로지스틱회귀에서 $\exp(\beta_1) =$ 승산비 (단, β_1 : 어떤 입력변수 x_1 에 대한 회귀계수)
 - $\exp(\beta_1) = 10$ 이면 x_1 이 1 증가할 때마다 성공의 오즈(odds)가 약 10배 증가함
 - 승산비가 1이면 효과 없음, 1보다 작으면 확률 감소, 1보다 크면 확률 증가로 해석함

```
data(iris)
a <- subset(iris, Species=='setosa' | Species=='versicolor')
a$Species<-factor(a$Species)
b <- glm(Species~Sepal.Length, data=a, family = binomial)
```

```
> coef(b)
(Intercept) Sepal.Length
-27.831451    5.140336

> exp(coef(b))['Sepal.Length']
Sepal.Length
170.7732
```

- $Y=1$ 이 'setosa' 일 경우, Sepal.Length가 한 단위 증가하면 'setosa'일 odds가 약 170배 증가함을 의미함
- Sepal.Length가 3 증가할 때, 승산비 : $\exp(\text{회귀계수} \times 3)$

```
> exp(coef(b)*3)['Sepal.Length']
Sepal.Length
4980338
```



🍀 " $z = \beta_0 + \beta_1 X$ "에서 회귀계수의 의미

β_0 (절편, intercept)

- 모든 X 가 0일 때의 log-odds 값
- 즉, 기준 상태에서 $P(Y=1)$ 의 로그 오즈(log odds)
- 확률이 아니라 log odds값이므로 음수·양수 모두 가능

β_1 (기울기, slope 계수)

- X 가 1단위 증가할 때, log odds가 β_1 만큼 변화한다.
- $\beta_1 > 0 \rightarrow X$ 가 증가하면 성공 확률 증가
- $\beta_1 < 0 \rightarrow X$ 가 증가하면 성공 확률 감소
- $\beta_1 = 0 \rightarrow$ 영향 없음

β_1 가 X 의 회귀계수일 때

- $\beta_1 = \log(\text{odds}_{X+1}/\text{odds}_X) = \log(\text{odds}_{X+1}) - \log(\text{odds}_X) = \log(\text{odds ratio})$
- odds_{X+1} : X 가 1단위 증가했을 때의 odds, odds_X : X 일 때의 odds
- 즉, β_1 은 X 가 1단위 변화할 때 log odds가 얼마나 변하는지를 나타내는 값
- e^{β_1} 은 X 가 1단위 변화할 때 odds가 몇 배 변하는지를 나타내는 값이다!

$\exp(\beta_1) = \text{odds ratio}$

- $\beta_1 = \log(\text{odds ratio})$ 이므로 양변에 exp를 취하면, $e^{\beta_1} = \text{odds ratio}$ 이다.
- 즉, X 가 1 증가할 때 odds가 e^{β_1} 배 변화한다.
- $\beta_1 = 0.7 \rightarrow e^{0.7} \approx 2.01 \rightarrow X$ 가 1 증가하면 성공 odds가 약 2배 증가한다.
- $\beta_1 = -1.2 \rightarrow e^{-1.2} \approx 0.30 \rightarrow X$ 가 1 증가하면 성공 odds가 0.3배로 감소한다.



로지스틱 회귀 분석 결과 해석 - Default 데이터셋 (1)

```
> summary(Default)
```

default	student	balance	income
No :9667	No :7056	Min. : 0.0	Min. : 772
Yes: 333	Yes:2944	1st Qu.: 481.7	1st Qu.:21340
		Median : 823.6	Median :34553
		Mean : 835.4	Mean :33517
		3rd Qu.:1166.3	3rd Qu.:43808
		Max. :2654.3	Max. :73554

종속변수

범주형 변수

- Default 데이터셋은 학생여부(student), 통장잔액(balance), 수입(income) 등을 사용하여 연체 여부(default)를 예측하는 분류 데이터셋이다.
- default와 student는 범주형 변수이며, 분석 시 No는 0, Yes는 1로 변환되어 사용된다.
- student는 범주형 변수이며, 분석 시 'No'를 기준 범주로 하고 'Yes'를 나타내는 studentYes 더미 변수가 생성되어 사용된다.
- balance, income은 연속형 변수이다.

기준 범주(Baseline Category)

- 범주형 변수(factor)를 회귀모형에 사용할 때, 여러 범주 중 하나를 기준(reference)으로 삼고 나머지와의 비교를 수행하는 기준 역할을 하는 범주를 말한다.
- student변수에 No, Yes의 두 가지 범주가 있을 때, R의 factor 기본 규칙에 따라 알파벳순으로 'No'가 기준 범주가 된다.
- 기준 범주는 항상 알파벳순으로 정해지는 것은 아니며, 범주형 변수에 levels(범주 순서)가 지정되어 있는 경우, 지정된 순서의 첫 번째 범주가 기준 범주가 된다.
- 이 경우 회귀모형에는 studentYes (Yes=1, No=0)의 더미 변수가 자동 생성된다.
- studentYes의 계수는 기준 범주(No)에 비해 Yes일 때 log-odds가 얼마나 증가 또는 감소하는가를 의미한다.



로지스틱 회귀 분석 결과 해석 - Default 데이터셋 (1)

단, 유의수준=0.05사용

```
> model = glm(default ~ ., data=Default, family=binomial)
> summary(model)
```

```
Call:
glm(formula = default ~ ., family = binomial, data = Default)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4691	-0.1418	-0.0557	-0.0203	3.7383

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.087e+01	4.923e-01	-22.080	< 2e-16 ***
studentYes	-6.468e-01	2.363e-01	-2.738	0.00619 **
balance	5.737e-03	2.319e-04	24.738	< 2e-16 ***
income	3.033e-06	8.203e-06	0.370	0.71152

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 2920.6 on 9999 degrees of freedom
Residual deviance: 1571.5 on 9996 degrees of freedom
AIC: 1579.5

Number of Fisher Scoring iterations: 8

- `glm(default ~., data=Default, family=binomial)` : 로지스틱 회귀(분류), 종속변수=default, 이항분류
- income 변수는 p-value가 0.71152이므로 종속변수 default에 통계적으로 유의미한 영향을 주는 변수가 아님
- student가 범주형 변수이기 때문에 더미변수(dummy)로 만들어져 사용됨 (studentYes 변수: student값이 Yes 일 때 1, No 일 때 0 값을 갖음)
- 회귀식에서 studentYes의 회귀계수가 음수이므로 student 값이 Yes 일 때, default(확률)을 감소시킴
$$\text{studentYes}(1)\text{일 때의 default} = -1.087e+01 - 6.468e-01 * \text{studentYes} + 5.737e-03 * \text{balance} + 3.033e-06 * \text{income}$$
- student값이 No 일 때, default를 변화시키지 않음 (studentYes의 값이 0으로 회귀식에 studentYes항이 포함되지 않기 때문)
$$\text{studentYes}(0)\text{일 때의 default} = -1.087e+01 + 5.737e-03 * \text{balance} + 3.033e-06 * \text{income}$$
- 데이터개수(n) = df + k(변수 개수) + 1
= 9996(Residual deviance의 degrees of freedom) + 3 + 1 = 10000



로지스틱 회귀 분석 결과 해석 - 이직 데이터셋

```
> summary(df)
```

```
   age
Min.  :17.00
1st Qu.:30.00
Median :35.00
Mean   :35.26
3rd Qu.:40.00
Max.   :61.00
```

```
   gender      education
Female:154 University:108
Male  :146 Graduate  : 92
                HighSchool:100
```

범주형 변수 → dummy 변수 생성

```
has_certificate years_of_experience
0:186           Min.   : 0.000
1:114           1st Qu.: 5.000
                Median : 7.000
                Mean    : 7.187
                3rd Qu.: 9.000
                Max.    :15.000
```

```
job_change
0:262
1: 38
```

종속변수

- 이직 데이터셋은 나이(age), 성별(gender), 학력(education), 자격증 취득 여부(has_certificate), 경력(years_of_experience)를 사용해 이직 여부(job_change)를 예측하기 위한 분류 데이터셋이다.
- gender는 범주형 변수이며, 분석 시 Female을 기준 범주로 하는 genderMale 더미 변수가 생성되어 사용된다.
- education은 University를 기준 범주로 하여 educationGraduate, educationHighSchool 더미 변수가 생성되어 사용된다.
- has_certificate는 0/1로 구성된 범주형 변수지만, 이진(dummy) 형태이므로 추가 변환 없이 그대로 사용된다.
- Age와 years_of_experience는 연속형 변수이다.



로지스틱 회귀 분석 결과 해석 - 이직 데이터셋

단, 유의수준 = 0.05사용

```
> model <- glm(job_change ~ ., data = df, family = binomial)
> summary(model)
```

```
Call:
glm(formula = job_change ~ ., family = binomial, data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.01979	0.73093	0.027	0.9784
age	-0.02340	0.01537	-1.523	0.1278
genderMale	0.29137	0.28060	1.038	0.2991
educationGraduate	-0.07871	0.35162	-0.224	0.8229
educationHighSchool	-0.48711	0.34155	-1.426	0.1538
has_certificate	0.69756	0.28325	2.463	0.0138 *
years_of_experience	-0.06334	0.02708	-2.339	0.0193 *

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 328.32  on 299  degrees of freedom
Residual deviance: 312.13  on 293  degrees of freedom
AIC: 326.13
```

Number of Fisher Scoring iterations: 4

- age의 계수가 음수(-0.02340)이므로 나이가 많을수록 이직 가능성이 낮아지는 경향이 있으나, p-value(0.1278)가 유의수준(0.05)보다 커 통계적으로 유의한 영향이라고 보기는 어려움
- genderMale은 계수가 양수(0.29137)이므로 남성이 여성보다 이직 가능성이 높아지는 방향이지만, p-value가 0.2991로 유의하지 않음
- has_certificate는 양수(0.69756)이므로 자격증이 있는 사람이 이직할 확률이 높고, p-value가 0.0138로 유의수준보다 작으므로 이직에 유의미한 영향을 미침
- years_of_experience의 계수는 음수(-0.06334)로 경력이 많을수록 이직 확률이 낮아지고, p-value가 0.0193으로 유의함
- 귀무 모형 이탈도(Null deviance) = 328.32
독립변수를 전혀 사용하지 않고 절편(Intercept) 만으로 종속변수(job_change)를 예측했을 때의 이탈도
- 잔차 이탈도(Residual deviance) = 312.13
독립변수를 포함한 현재 모델의 오차(불일치) 정도
- 이탈도(deviance)의 값이 작을수록 모델이 데이터를 더 잘 설명 함
- 이탈도 감소량 : Null deviance - Residual deviance
= 328.32 - 312.13 = 16.19



로지스틱 회귀 분석 결과 해석 - Default 데이터셋 (2)

```
Call:
glm(formula = default ~ balance + student, family = binomial,
    data = Default)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.075e+01  3.692e-01 -29.116  < 2e-16 ***
balance      5.738e-03  2.318e-04  24.750  < 2e-16 ***
studentYes   -7.149e-01  1.475e-01  -4.846  1.26e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 2920.6  on 9999  degrees of freedom
Residual deviance: 1571.7  on 9997  degrees of freedom
AIC: 1577.7

Number of Fisher Scoring iterations: 8
```

```
> round(exp(coef(model)), 3)
(Intercept)    balance studentYes
      0.000      1.006      0.489
```

모델의 회귀계수에 exp 함수를 적용하면 해당 변수들의 odds ratio를 얻을 수 있으며, balance는 1.006, studentYes는 0.489로 계산된다.

- balance가 1단위 증가하면 default의 odds가 1.006배가 됨
- student가 Yes(=1)일 때 default의 odds는 기준 범주(No)에 비해 0.489배가 됨

Odds ratio가 1보다 클 때는 승산 증가율을 구할 수 있다.

- 승산 증가율 = $(\text{odds ratio} - 1) * 100\%$
- balance: $(1.006 - 1) * 100\% = 0.006 * 100\% = 0.6\%$
- balance가 1 단위 증가할 때 default의 odds가 약 0.6% 증가

Odds Ratio가 1보다 작을 때는 승산 감소율을 구할 수 있다.

- 승산 감소율 = $(1 - \text{odds ratio}) * 100\%$
- studentYes: $(1 - 0.489) * 100\% = 0.511 * 100\% = 51.1\%$
- student가 Yes일 때, default의 odds가 기준 범주(No) 대비 약 51.1% 감소